

PROJET : At&T Spam Detector



Objectif du Projet

- Détection automatique des SMS spam (spam vs ham)
- Basée uniquement sur le contenu du message
- Approche par Deep Learning




Problématique

L'augmentation des spams nuisant à l'expérience utilisateur.


Volume du dataset d'entraînement : 5572 exemples

Proportion de Spam dans la cible : 13%

Proportion de Spam dans la cible : 13%



Modèle Baseline : Regression Logistique avec une vectorisation par la méthode TF-IDF



	precision	recall	f1-score	support
0	0.96	1.00	0.98	903
1	0.99	0.71	0.83	131
accuracy			0.96	1034
macro avg	0.97	0.85	0.90	1034
weighted avg	0.96	0.96	0.96	1034

Chiffres Clés


99%

Précision
Peu de Faux Positifs

29%

Faux Négatifs
Spams manqués

Modèle Deep Learning : Architecture : Fine-tuning de DistilBERT



Configuration de l'entraînement

Modèle

distilbert-base-uncased

Transfert Learning

Learning Rate

2e-5

Ajustement fin pour préserver les acquis

Tokenisation

128 tokens


format court sms

Sécurité

Early Stopping

Limite activement l'overfitting

Modèle Deep Learning (modèle DistilBERT) résultat



	precision	recall	f1-score	support
0	0.99	1.00	1.00	903
1	0.98	0.95	0.97	131
accuracy			0.99	1034
macro avg	0.99	0.98	0.98	1034
weighted avg	0.99	0.99	0.99	1034

Chiffres Clés

98%

Précision
Peu de Faux Positifs

5%

Faux Négatifs
Spams manqués


Bilan Opérationnel et Analyse des Erreurs

0.2%

de messages sain bloqué

6x moins

de spams manqués



Recommandations

Seuil Dynamique

Mise en place d'un seuil de décision dynamique pour équilibrer sécurité et confort utilisateur.

Enrichissement Contextuel

Intégration native des données supplémentaires sur les utilisateurs pour renforcer la détection.

Industrialisation MLOps

Déploiement d'une solution MLOps pour le suivi des performances et la mise à jour continue.

Modèles Spécialisés

Extension du modèle vers des architectures spécialisées dans la détection des spams sophistiqués.



PROJET STEAM



Des questions