



# Prédiction du rendement agricole

## Anticiper pour mieux planifier

Exploiter la puissance du Machine Learning pour anticiper les productions agricoles et optimiser la planification stratégique des ressources.



Unité : kg/ha





# Prédiction du rendement agricole (kg/ha)



## Planification

Le rendement est le pilier de la sécurité alimentaire et de la gestion économique des exploitations.



## Imprévisibilité

Anticiper avec précision reste complexe face aux aléas climatiques et biologiques.




## Géographie

Les disparités régionales et les sols influencent drastiquement les résultats finaux.

## Le problème :

Peut-on prédire le rendement à partir des données disponibles afin de mieux planifier ?






# Notre solution

- Un modèle de Machine Learning performant pour prédire le rendement agricole

## Performance du modèle



Résultat obtenu sur les données de test





# Exemple de prédiction

Localisation & Culture


**France / Pommes**

Rendement Réel

**32 822** kg/ha

Rendement Prédit

**31 947** kg/ha



Erreur relative : 2,7%



# Prédiction du rendement agricole

## La démo

97.3%  
Accuracy


97.3%  
Accuracy

97.3%  
Accuracy

[Assistant AgriTech](#)



# Comment ça marche (pipeline)



Un pipeline automatisé pour transformer les données agricoles en prévisions précises





# I- Collecte des données



## Crop Yield Prediction

Source principale via Kaggle pour les données de rendement de base.

[Crop Yield Prediction Dataset](#)



## FAOSTAT (FAO)

Données officielles sur l'agriculture et l'utilisation des terres mondiales.

[FAOSTAT \(Food & Agriculture Organisation\)](#)



## CRU (Climatic Unit)

Indicateurs climatiques pour enrichir le contexte environnemental.

[CRU \(Climatic Research Unit\)](#)

Reconstruction du dataset initial Kaggle à partir des sources FAOSTAT & CRU pour enrichir les données



## II- Identification des variables



### Géographie & Temps

39 Pays d'Europe  
24 Années de données



### Production

132 Types de récolte  
**Valeur objective :**  
Rendement (kg/ha)



### Inputs & Sol

3 types de nutriments  
5 types d'additifs  
(masses en tonnes)



### Climat

10 Variables climatiques

Taille du dataset : 64 368 enregistrements & 24 colonnes





## II- Nettoyage & Encodage du dataset




### Nettoyage

- **Suppression**
  - Lignes sans rendement « Yield »
  - Colonne « **Year** » (période de 24 ans)
  - Colonnes climatiques
- **Filtrage & Traitement**
  - remplacement des valeurs manquantes
  - Unités « **kg/ha** » uniquement
  - Top 60 des récoltes les plus fréquentes



### Encodage

- **TargetEncoder** : Chaque nom de catégorie (pays, type de culture) est remplacé par son rendement moyen observé sur la période étudiée.




Taille finale : **28 936** enregistrements & **11** colonnes




## II- Distribution des Rendements : son évolution

- Rendements de 60 récoltes majeures  
AVANT nettoyage du jeu de données



- Rendements de 60 récoltes majeures  
APRÈS nettoyage du jeu de données



Préparation du jeu de données



## III- Choix et Optimisation du Modèle



### Random Forest

Le modèle prend plein de décisions différentes (comme des mini-arbres de décision) et combine leurs réponses pour obtenir un résultat plus fiable.



### XGBoost

Le modèle apprend en plusieurs étapes, en corrigeant ses erreurs à chaque fois pour devenir de plus en plus précis.



### LightGBM

C'est une version plus rapide et optimisée de XGBoost, qui arrive au même résultat mais plus efficacement.




### CatBoost

C'est un modèle spécialement conçu pour bien gérer les données contenant des catégories (comme des pays ou des types de cultures).

L'optimisation de ces modèles permet d'identifier la meilleure architecture pour des prédictions fiables.



## IV- Résultats des prédictions des modèles



| Training duration |         |
|-------------------|---------|
| CatBoost          | 3.2 min |
| LightGBM          | 32.5 s  |
| XGBRegressor      | 12.1 s  |
| RandomForest      | 23.1 s  |



### R<sup>2</sup>\_test

Excellente performance sur le test set (CatBoost : 0.93)



### R<sup>2</sup>\_train

Score très élevé sur le train set (CatBoost : 0.98) traduisant une forte capacité d'apprentissage



### Équilibre

Faible overfitting (CatBoost : 0.05) garantissant une excellente capacité de généralisation




### CatBoost

Meilleures Performances & Overfitting pour  $t_{run}$  modéré

**CatBoost confirme sa position de meilleur modèle.**



# Comment ça marche (déploiement)



Une infrastructure robuste pour un déploiement scalable et performant.



# Difficultés rencontrées



## Qualité des données

- Gestion des valeurs manquantes et des incohérences.
- Suppression des données climatiques (CRU).



## Variables catégorielles

- Encodage précis (Target Encoder) pour les pays et cultures.
- Contrôle du nombre de variables (éviter le surdimensionnement).

Surmonter ces obstacles a été crucial pour garantir la fiabilité des prédictions du modèle.



# Conclusion & Perspectives d'amélioration



## Modèle performant

Le modèle prédit le rendement avec une bonne précision et une erreur faible.




## Application concrète

Un outil exploitable pour aider à anticiper les rendements et améliorer les décisions agricoles.



## Données Météo

Intégrer des données météo pour améliorer la précision et anticiper l'évolution dans le temps.



Vers un outil d'aide à la décision basé sur les données agricoles





“Prédire le rendement, c’est  
semer la certitude dans un  
champ d'incertitudes.”

**Merci !**

Adrien Leclerc / Expert en agriculture numérique